

얼굴인식 2차 과제

생체인증보안

사이버보안전공

1871085

주유연



01

Data

- Read Data
- Data Augmentation



02

Split Data

- train_test_split



03

Model

- CNN Model
- Hyperparameter tuning
- Training Result



04

Evaluate Model

- Confusion Matrix



Given Data

- 350명의 얼굴 데이터가 1명당 3개씩 총 1050개의 얼굴 이미지 데이터가 주어짐.
- 각 파일명의 앞쪽 숫자는 label을 의미함.

```
# 이미지 목록
images = glob.glob('./02_face_training/*.BMP')
len(images)
```

1050

```
r = re.compile('#d+')

img = [] # 이미지
label = [] # 라벨

for fname in images:
    l = r.findall(fname)[1]
    label.append(l)
    im = pilimg.open(fname)
    pix = np.array(im) / 255. # Normalize
    img.append(pix)
```

```
X = np.array(img)
X = X.reshape(X.shape[0], 56, 46, 1)
X.shape # img shape
```

(1050, 56, 46, 1)

```
y = np.array(label, dtype='int32')
y # label
```

array([128, 127, 128, ..., 336, 335, 336], dtype=int32)

데이터 불러오기

- glob 함수를 이용해 파일명을 불러오고, 파일명에서 label을 읽어 별도의 리스트에 저장함.
- 불러온 이미지를 numpy array로 변환함.

얼굴 이미지 확인



- Normalization


```
# 얼굴 이미지  
plt.title('Face')  
plt.imshow(X[0].reshape(56,46), cmap='gray')  
print(X[0].shape)  
print(y[0])
```

(56, 46, 1)
128




Data Augmentation

- 1명당 3개의 데이터는 얼굴을 구별하기에 부족하다고 판단.
- 얼굴 이미지를 blur처리하고 이미지의 각도를 비틀어 새 데이터를 생성함. (크게 변형되지 않도록)
- 각 이미지당 9개의 추가 augmented image를 생성하여 총 9450개의 데이터를 확보함.



- GaussianBlur
- Affine – translate, rotate



최종 Data

```
# 생성한 이미지
x_d = np.array(x_d)
y_d = np.array(y_d)
print(x_d.shape)
print(y_d.shape)
```

```
(9450, 56, 46, 1)
(9450,)
```

```
# 기존 이미지
print(X.shape)
print(y.shape)
```

```
(1050, 56, 46, 1)
(1050,)
```

```
# 기존 이미지, 생성 이미지 합치기
X_data = np.concatenate([X, x_d], axis=0)
y_data = np.concatenate([y, y_d], axis=0)
print(X_data.shape)
print(y_data.shape)
```

```
(10500, 56, 46, 1)
(10500,)
```

Split Data

- sklearn.model_selection의 train_test_split 함수 이용.
- Train : Test의 비율은 8:2로 하고, stratify 옵션을 주어 label이 균등하게 나뉘도록 함.
- X_test, y_test는 모델 훈련 후 evaluate으로 이용함.

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X_data, y_data, test_size=0.2, shuffle=True, stratify=y_data, random_state=101)
```

```
X_train=X_train.astype('float32')
y_train=y_train.astype('int32')
X_test=X_test.astype('float32')
y_test=y_test.astype('int32')
```

```
X_train = X_train.reshape(X_train.shape[0], 56, 46, 1)
X_test = X_test.reshape(X_test.shape[0], 56, 46, 1)
print(X_train.shape, y_train.shape, X_test.shape, y_test.shape)
```

```
(8400, 56, 46, 1) (8400,) (2100, 56, 46, 1) (2100,)
```


Label one-hot encoding (원-핫 인코딩)

- 모델 학습 시 loss function으로 categorical_crossentropy를 사용하기 위해 label을 원-핫 인코딩해줌.
- Label 값은 1~350 범위로 저장되어 있는데 이를 희소행렬로 변환해준다.
- 이 때, 0에 해당하는 data가 없기에 학습 자체에는 영향을 주지 못한다고 판단하여 따로 label을 변경하진 않았음.

```
from keras.utils import to_categorical  
y_train = to_categorical(y_train, num_classes=351)  
y_test = to_categorical(y_test, num_classes=351)
```

2차 추가로 시도해본 모델

	Aug-blur	Testset rate	Layer	Dropout (Conv/MaxPool)	Dropout (Dense)	regularizer	optimizer	Activation
01	0-0.1	0.1	filter 12 → 6	X	X	Dense(64) l2	Adam	relu
02	0-0.1	0.1	filter 12 → 6	X	0.1	Dense(64) l2	Adam	relu
03	0-0.1	0.1	filter 12	X	0.1	Dense(64) l2	Adam	relu
04	0-0.05	0.1	filter 12	X	0.1	Dense(64) l2	Adam	relu
05	0-0.05	0.1	filter 12	X	0.1	Dense(256) l2 Dense(64) l2	Adam	relu
06	0-0.05	0.1	filter 6	X	X	Dense(256) l2 Dense(64) l2	Adam	relu
07	0-0.05	0.1	filter 12	X	0.1	Dense(64) l2	Adam	relu
08	0-0.05	0.2	filter 12	X	0.1	Dense(32) l2	Adam	selu
09	0-0.05	0.2	filter 12	X	0.1	Dense(32) l2	Nadam	selu
10	0-0.05	0.2	filter 12	X	0.2	Dense(32) l2	Adam	selu

제출한 모델

	Aug-blur	Testset rate	Layer	Dropout (Conv/MaxPool)	Dropout (Dense)	regularizer	optimizer	Activation
01	0-0.1	0.1	filter 12 → 6	X	X	Dense(64) l2	Adam	relu
02	0-0.1	0.1	filter 12 → 6	X	0.1	Dense(64) l2	Adam	relu
03	0-0.1	0.1	filter 12	X	0.1	Dense(64) l2	Adam	relu
04	0-0.05	0.1	filter 12	X	0.1	Dense(64) l2	Adam	relu
05	0-0.05	0.1	filter 12	X	0.1	Dense(256) l2 Dense(64) l2	Adam	relu
06	0-0.05	0.1	filter 6	X	X	Dense(256) l2 Dense(64) l2	Adam	relu
07	0-0.05	0.1	filter 12	X	0.1	Dense(64) l2	Adam	relu
08	0-0.05	0.2	filter 12	X	0.1	Dense(32) l2	Adam	selu
09	0-0.05	0.2	filter 12	X	0.1	Dense(32) l2	Nadam	selu
10	0-0.05	0.2	filter 12	X	0.2	Dense(32) l2	Adam	selu

1차 제출 때의 모델과 비교

```
def build_model():
    learning_rate = 0.00001
    width = 56
    height = 46
    METRICS = [
        tf.keras.metrics.BinaryAccuracy(name='accuracy')
    ]
    model = Sequential()
    model.add(Conv2D(filters=64, kernel_size=(2,2), padding='same', activation='relu', input_shape=(width, height, 3)))
    model.add(MaxPooling2D(pool_size=(2,2)))

    model.add(Conv2D(filters=32, kernel_size=(2,2), padding='same', activation='relu'))
    model.add(Conv2D(filters=32, kernel_size=(2,2), padding='same', activation='relu'))
    model.add(MaxPooling2D(pool_size=(2,2)))

    model.add(Flatten())
    model.add(Dense(512, activation='relu'))
    model.add(Dropout(0.1))
    model.add(Dense(64, activation='relu', kernel_regularizer='l2'))
    model.add(Dropout(0.1))
    model.add(Dense(351, activation='softmax'))
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])
    return model

model = build_model()
model.summary()
```



```
def build_model():
    learning_rate = 0.00001
    width = 56
    height = 46
    METRICS = [
        tf.keras.metrics.BinaryAccuracy(name='accuracy')
    ]
    model = Sequential()
    model.add(Conv2D(filters=12, kernel_size=(3,3), padding='same', activation='selu', input_shape=(width, height, 3)))
    model.add(Conv2D(filters=12, kernel_size=(3,3), padding='same', activation='selu'))
    model.add(MaxPooling2D(pool_size=(2,2)))

    model.add(Flatten())
    model.add(Dense(256, activation='selu'))
    model.add(Dropout(0.1))
    model.add(Dense(32, activation='selu', kernel_regularizer='l2'))
    model.add(Dense(351, activation='softmax'))
    model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])
    return model

model = build_model()
model.summary()
```

- 2층 CNN 구조에서 1층 CNN 구조로 변경함
- Filter 크기를 64&32에서 12로 줄이고, kernel_size를 (2, 2)에서 (3, 3)으로 변경함.
- 각 layer에서의 activation function을 relu에서 selu로 변경함.
- Dense층의 구조를 Dropout층을 하나 빼고, 512-64-351차원에서 256-32-351차원으로 변경함.

1차 제출 때의 모델과 비교

Model: "sequential_10"

Layer (type)	Output Shape	Param #
conv2d_40 (Conv2D)	(None, 56, 46, 64)	320
conv2d_41 (Conv2D)	(None, 56, 46, 64)	16448
max_pooling2d_20 (MaxPooling)	(None, 28, 23, 64)	0
conv2d_42 (Conv2D)	(None, 28, 23, 32)	8224
conv2d_43 (Conv2D)	(None, 28, 23, 32)	4128
max_pooling2d_21 (MaxPooling)	(None, 14, 11, 32)	0
flatten_10 (Flatten)	(None, 4928)	0
dense_32 (Dense)	(None, 512)	2523648
dropout_6 (Dropout)	(None, 512)	0
dense_33 (Dense)	(None, 64)	32832
dense_34 (Dense)	(None, 351)	22815

Total params: 2,608,415
Trainable params: 2,608,415
Non-trainable params: 0




Model: "sequential_10"

Layer (type)	Output Shape	Param #
conv2d_39 (Conv2D)	(None, 56, 46, 12)	120
conv2d_40 (Conv2D)	(None, 56, 46, 12)	1308
conv2d_41 (Conv2D)	(None, 56, 46, 12)	1308
max_pooling2d_13 (MaxPooling)	(None, 28, 23, 12)	0
flatten_10 (Flatten)	(None, 7728)	0
dense_30 (Dense)	(None, 256)	1978624
dropout_6 (Dropout)	(None, 256)	0
dense_31 (Dense)	(None, 32)	8224
dense_32 (Dense)	(None, 351)	11583

Total params: 2,001,167
Trainable params: 2,001,167
Non-trainable params: 0


Training and Validation Loss

- KFold (k=4) Validation
- Fold 별 Train Loss와 Validation Loss
- Fold마다 loss가 줄어들었음을 확인할 수 있음.



Training and Validation Accuracy

- KFold (k=4) Validation
- Fold 별 Train Accuracy 와 Validation Accuracy




예측 결과 확인

- Test set으로 분리한 데이터의 일부의 실제 label과 예측 label을 확인함.

```
# 예측결과
plt.title('predicted face')
this_img = X_test[1].reshape(56,46)
plt.imshow(this_img, cmap='gray')
print(this_img.shape)
print('예측: ', preds[1])
print('실제: ', y_test_origin[1])
#X_test[0]
```

```
(56, 46)
예측: 342
실제: 342
```



Accuracy, Precision, Recall, F1 score

- Multi-class model임을 고려하여 평가지표들을 계산함.
- 각 label마다의 confusion matrix TP, FN, FP, TN의 평균인 Macro Average를 계산함.

```
from sklearn.metrics import classification_report  
print(classification_report(y_test_origin, preds, zero_division=1))
```

	precision	recall	f1-score	support
1	1.00	1.00	1.00	6
2	1.00	1.00	1.00	6
3	1.00	1.00	1.00	6
4	1.00	1.00	1.00	6
5	1.00	1.00	1.00	6
6	1.00	1.00	1.00	6

	Precision	Recall	F1-score	
accuracy			1.00	2100
macro avg	1.00	1.00	1.00	2100
weighted avg	1.00	1.00	1.00	2100

Test 예측 결과

	Image	Answer
15	1	5
28	2	270
359	3	188
248	4	214
290	5	303
...
199	696	93
402	697	182
481	698	289
534	699	225
551	700	281

700 rows × 2 columns

자체 평가

- Data Augmentation을 무작정 하면 안되고 모델의 목적이나 데이터의 형태에 따라 augmentation 정도를 잘 조절해야 한다는 것을 알았다.
- 네트워크가 깊다고 반드시 더 좋은 성능을 내지는 않는다. (1차 2층CNN vs 2차 1층CNN 구조)
- 모델 설계 시, 다양한 activation function을 조절해보며 적합한 함수를 찾아봐야 한다.
- Optimizer도 adam 외에 nadam, rmsprop 등을 시도해보며 적합한 것을 찾아봐야 한다.



감사합니다